

World Action Models 的三种典型范式

2026 年 6 月 26 日

1 总览

World Action Model, 简称 WAM, 试图把世界预测与动作生成统一起来。它不同于普通策略模型只学习

$$p(a_t \mid o_t, \ell),$$

也不同于纯 world model 只学习

$$p(o_{t+1:t+H} \mid o_{\leq t}, a_{t:t+H-1}).$$

WAM 的核心是建模动作与未来世界之间的耦合关系。典型目标可以写为:

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

当前 WAM 文献中可以抽象出三种代表性范式:

1. Joint Video-Action Modeling: 联合生成未来视频和动作;
2. Imagine-Then-Execute: 先想象未来, 再根据未来执行;
3. Fast-WAM: 训练时学习未来预测, 推理时跳过显式未来生成。

2 范式一: Joint Video-Action Modeling

2.1 核心思想

Joint Video-Action Modeling 把未来观测和动作放在同一个生成建模问题中。模型不是先生成视频再生成动作, 也不是只预测动作, 而是直接学习联合分布:

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

直观上, 模型需要同时回答两个问题:

- 未来世界会怎样变化?
- 哪些动作与这些未来变化相匹配?

这类方法强调动作和视频之间的同步建模。动作不是附加模块, 而是和未来视觉 token 一起进入模型。

2.2 训练目标

训练数据来自机器人演示轨迹。每个训练样本通常包含过去观测、语言指令、未来观测和未来动作：

$$(o_{\leq t}, \ell, o_{t+1:t+H}, a_{t:t+H-1}).$$

Joint Video-Action Modeling 的目标是让模型在给定过去观测和语言指令时，同时恢复未来视觉内容和动作序列。

如果使用扩散模型，可以令干净数据为：

$$x_0 = [z_{t+1:t+H}^o, z_{t:t+H-1}^a],$$

其中 z^o 是未来视频或图像的 latent token, z^a 是动作 token。这里的 x_0 不是单纯图像，而是“未来世界 token + 动作 token”的拼接对象。条件为：

$$c = [o_{\leq t}, \ell].$$

训练时先随机采样一个噪声强度 τ ，再把高斯噪声 ϵ 加到干净样本 x_0 上，得到带噪样本：

$$x_\tau = \sqrt{\bar{\alpha}_\tau} x_0 + \sqrt{1 - \bar{\alpha}_\tau} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

模型看到的是 (x_τ, τ, c) ，任务是预测刚才加入的噪声 ϵ 。扩散训练目标为：

$$\mathcal{L}_{\text{joint}} = \mathbb{E}_{x_0, \epsilon, \tau} \left[\|\epsilon - \epsilon_\theta(x_\tau, \tau, c)\|_2^2 \right].$$

这个 loss 的含义是：模型必须学会在条件 c 的约束下，把一个被污染的“未来世界 + 动作”样本逐步去噪回真实演示数据。训练完成后，推理时可以从纯噪声开始，反复去噪，生成与当前观测和语言指令一致的未来视觉 token 与动作 token。

如果未来视觉、动作和 proprioception 的尺度差异很大，实践中常会对不同 token 使用不同编码器、归一化方式或 loss 权重：

$$\mathcal{L}_{\text{joint}} = \lambda_o \mathcal{L}_{\text{video}} + \lambda_a \mathcal{L}_{\text{action}} + \lambda_q \mathcal{L}_{\text{state}}.$$

但概念上，它们仍然服务于同一个目标：学习一个条件联合分布，使动作和未来世界在同一个生成过程中互相约束。

2.3 推理流程

推理时，模型从噪声开始生成：

$$(\hat{o}_{t+1:t+H}, \hat{a}_{t:t+H-1}) \sim p_\theta(\cdot \mid o_{\leq t}, \ell).$$

执行时通常只执行第一个动作或 action chunk：

$$a_t = \hat{a}_t \quad \text{或} \quad a_{t:t+K-1} = \hat{a}_{t:t+K-1}.$$

2.4 优点与问题

优点是结构统一, 动作和未来观测可以互相约束。模型生成的动作天然对应某种未来世界变化, 因此适合表达多模态动作分布和复杂交互。

问题是推理成本较高, 尤其当未来视频 token 很多时, 扩散去噪会非常慢。此外, 联合建模要求模型同时处理视觉、动作和语言, 训练难度较高。

3 范式二: Imagine-Then-Execute

3.1 核心思想

Imagine-Then-Execute 把 WAM 分成两个阶段:

先想象未来, 再根据未来选择动作。

第一阶段生成未来观测:

$$\hat{o}_{t+1:t+H} \sim p_{\theta}(o_{t+1:t+H} \mid o_{\leq t}, \ell).$$

第二阶段根据当前观测和想象出的未来预测动作:

$$a_{t:t+H-1} \sim \pi_{\phi}(a_{t:t+H-1} \mid o_{\leq t}, \hat{o}_{t+1:t+H}, \ell).$$

它的直觉是: 如果模型能想象任务成功的未来状态, 那么动作模型可以学习如何到达这个未来。

3.2 与 inverse dynamics 的关系

第二阶段常常接近 inverse dynamics problem。Forward dynamics 问:

$$(o_t, a_t) \mapsto o_{t+1}.$$

Inverse dynamics 问:

$$(o_t, o_{t+1}) \mapsto a_t.$$

Imagine-Then-Execute 可以看作先生成目标未来, 再用 inverse dynamics 或 action decoder 反推出动作。

3.3 训练目标

Imagine-Then-Execute 通常把训练拆成两个目标。第一部分训练 future model, 使其根据过去观测和语言指令生成未来观测:

$$\mathcal{L}_{\text{future}} = -\log p_{\theta}(o_{t+1:t+H} \mid o_{\leq t}, \ell).$$

如果 future model 是扩散视频模型, 这个负对数似然通常也通过 denoising loss 近似: 模型学习从带噪未来视频 token 中预测噪声。

第二部分训练 action model, 使其根据当前观测和未来观测恢复动作:

$$\mathcal{L}_{\text{action}} = -\log \pi_{\phi}(a_{t:t+H-1} \mid o_{\leq t}, o_{t+1:t+H}, \ell).$$

在训练时, 这里的未来观测通常使用真实演示中的未来帧, 而不是模型生成的未来帧。这样 action model 学到的是: 如果当前状态和目标未来都给定, 哪些动作能连接二者。

总训练目标可以写成:

$$\mathcal{L} = \mathcal{L}_{\text{future}} + \beta \mathcal{L}_{\text{action}}.$$

因此, 这一范式的训练逻辑是“先学会想象未来, 再学会从未来反推动作”。它的风险在于训练时 action model 看到的未来是真实未来, 推理时看到的未来却是生成未来, 两者分布可能不完全一致。

3.4 Planning 形式

如果生成多个未来候选:

$$\hat{o}_{t+1:t+H}^{(i)} \sim p_{\theta}, \quad i = 1, \dots, N,$$

可以用 reward model 或 value model 评分:

$$J^{(i)} = \hat{V}_{\psi}(\hat{o}_{t+H}^{(i)}).$$

选择:

$$i^* = \arg \max_i J^{(i)}.$$

再由动作模型生成对应动作:

$$a_{t:t+H-1} \sim \pi_{\phi}(\cdot \mid o_{\leq t}, \hat{o}_{t+1:t+H}^{(i^*)}, \ell).$$

3.5 优点与问题

优点是模块化清晰: 视频模型负责未来想象, 动作模型负责执行。这种结构便于利用大规模预训练视频模型, 也便于在未来空间中做候选选择。

问题是显式 future imagination 很慢, 尤其是视频扩散模型需要多步 denoising。另一个问题是 generated future 和 executable action 之间可能不一致: 模型可能想象出看起来合理但机器人实际上难以实现的未来。

4 范式三: Fast-WAM

4.1 核心思想

Fast-WAM 的出发点是质疑一个常见假设: WAM 是否必须在测试时显式生成未来视频? 它将训练和推理解耦。训练时保留视频预测目标:

$$\mathcal{L} = \mathcal{L}_{\text{action}} + \lambda \mathcal{L}_{\text{video}}.$$

但推理时不生成未来视频, 而是直接根据当前观测的 latent representation 输出动作:

$$a_{t:t+H-1} \sim \pi_{\theta}(a_{t:t+H-1} \mid z_t, \ell), \quad z_t = f_{\theta}(o_{\leq t}).$$

4.2 训练阶段

训练时模型仍然学习 future prediction:

$$p_{\theta}(o_{t+1:t+H} \mid o_{\leq t}, a_{t:t+H-1}, \ell),$$

或在 latent space 中预测未来视频 token。该目标迫使模型学习物理动态、运动规律和任务相关时间结构。

同时, 模型学习动作预测:

$$p_{\theta}(a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

因此视频预测在这里主要是 representation learning 的辅助目标。

更具体地说, Fast-WAM 的训练目标可以拆成两部分。第一部分是动作预测:

$$\mathcal{L}_{\text{action}} = -\log p_{\theta}(a_{t:t+H-1} \mid z_t, \ell), \quad z_t = f_{\theta}(o_{\leq t}).$$

第二部分是视频预测或视频 denoising:

$$\mathcal{L}_{\text{video}} = -\log p_{\theta}(o_{t+1:t+H} \mid z_t, a_{t:t+H-1}, \ell),$$

或其扩散形式。总目标为:

$$\mathcal{L} = \mathcal{L}_{\text{action}} + \lambda \mathcal{L}_{\text{video}}.$$

这里最重要的是 $\mathcal{L}_{\text{video}}$ 的角色变化。它不是为了让模型在测试时真的生成未来视频, 而是作为辅助监督, 迫使 z_t 包含对物理动态、物体交互和任务进展有用的信息。换言之, Fast-WAM 把视频预测从“推理步骤”降级为“训练时的表征学习约束”。

4.3 推理阶段

推理时, 模型不再执行:

$$\hat{o}_{t+1:t+H} \sim p_{\theta}.$$

它只使用视频模型或 world encoder 提供的 latent state:

$$z_t = f_{\theta}(o_{\leq t}),$$

然后由 action head 或 action expert 生成动作:

$$\hat{a}_{t:t+H-1} = g_{\theta}(z_t, \ell).$$

4.4 关键假设

Fast-WAM 的核心假设是:

WAM 的主要收益来自训练时的视频预测目标, 而不是测试时显式生成未来。

换句话说, 未来预测的作用是塑造更好的世界表征, 而不一定要在推理时真的把未来视频生成出来。

4.5 优点与问题

优点是推理速度快，避免了测试时视频扩散的高延迟。它更适合 real-time control，尤其是机器人任务中控制频率有限、延迟敏感。

问题是它牺牲了显式 planning 的能力。模型不能在测试时比较多个想象未来，也较难利用 value ranking 做 best-of- N 搜索。因此它更像一个被 world-model training 强化过的 policy，而不是完整的 model-based planner。

5 三种范式对比

范式	训练时是否预测未来	推理时是否生成未来	动作如何产生
Joint Video-Action	是	是	与未来视频联合生成
Imagine-Then-Execute	是	是	由想象未来反推出动作
Fast-WAM	是	否	由 latent representation 直接预测

从建模角度看：

$$\text{Joint Video-Action} : p(o_{future}, a_{future} \mid o_{past}, \ell).$$

$$\text{Imagine-Then-Execute} : p(o_{future} \mid o_{past}, \ell) \quad \text{then} \quad p(a_{future} \mid o_{past}, o_{future}, \ell).$$

$$\text{Fast-WAM} : \mathcal{L}_{video} \text{ for training, } p(a_{future} \mid z_t, \ell) \text{ for inference.}$$

6 如何阅读相关论文

阅读一篇 WAM 论文时，应先判断它属于哪种范式。可以依次追问：

1. 动作和未来视频是联合生成，还是分阶段生成？
2. 视频预测只用于训练，还是也用于测试时决策？
3. 推理时是否显式生成未来图像或视频？
4. 是否使用 value function 对未来候选排序？
5. 动作是单步输出，还是 action chunk？
6. 延迟瓶颈来自视频生成、动作扩散，还是多候选采样？

7 与三篇材料的对应

- Fast-WAM 对应第三种范式。它的贡献在于证明或至少经验性支持：训练时的视频建模可能比测试时显式未来想象更关键。
- Cosmos Policy 更接近联合建模与 planning 的组合。它把 action、future state 和 value 放入统一生成框架，并用候选未来与价值预测辅助决策。

- WM as simulator 不是典型 WAM 入门论文。它更关注把 world model 作为 learned simulator, 用来生成训练场景或 synthetic data。

8 一句话总结

Joint Video-Action 的核心是“动作和未来一起生成”；Imagine-Then-Execute 的核心是“先想象未来，再反推动作”；Fast-WAM 的核心是“训练时学习未来，推理时直接行动”。

三者的根本分歧在于：未来预测到底应该作为测试时 planning 的显式步骤，还是只作为训练时塑造世界表征的辅助目标。