

World Action Models: 数学化学习笔记

2026 年 6 月 26 日

1 学习目标

World Action Model, 简称 WAM, 不应只理解为“会生成未来视频的机器人模型”。更严格地说, WAM 研究的是:

在部分可观测、语言条件、连续控制的序列决策问题中, 如何联合建模世界动态、动作分布与任务价值。

它处在 POMDP、world model、imitation learning、video prediction、diffusion policy 和 model-based planning 的交叉处。

2 从 POMDP 定义问题

具身控制任务可以形式化为一个部分可观测马尔可夫决策过程:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{O}, T, \Omega, R, \gamma).$$

其中:

- $\mathcal{S}$ 是真实环境状态空间, 通常不可完全观测;
- $\mathcal{A}$ 是动作空间, 例如关节角速度、末端位姿增量或夹爪开合;
- $\mathcal{O}$ 是观测空间, 例如 RGB 图像、多视角图像和 proprioception;
- $T(s_{t+1} | s_t, a_t)$ 是环境动力学;
- $\Omega(o_t | s_t)$ 是观测模型;
- $R(s_t, a_t)$ 是奖励函数;
- γ 是折扣因子。

实际机器人通常不能直接访问 s_t , 只能得到观测 o_t 。若任务由语言给定, 记语言指令为 $\ell \in \mathcal{L}$ 。一个普通策略模型学习:

$$\pi_{\theta}(a_t | o_{\leq t}, a_{< t}, \ell).$$

很多 VLA 模型进一步近似为反应式策略:

$$\pi_{\theta}(a_t | o_t, \ell).$$

3 WAM 的核心建模对象

WAM 的关键不是只预测动作，而是联合建模动作与未来世界。一个典型 WAM 近似如下条件分布：

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

如果引入机器人自身状态 q_t ，例如关节角、末端位姿和夹爪状态，则可写为：

$$p_{\theta}(o_{t+1:t+H}, q_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, q_{\leq t}, \ell).$$

如果模型还预测价值，则可扩展为：

$$p_{\theta}(o_{t+1:t+H}, q_{t+1:t+H}, a_{t:t+H-1}, V_{t+H} \mid o_{\leq t}, q_{\leq t}, \ell).$$

这类建模方式对应 Cosmos Policy 一类方法：把 action、future state 和 value 都纳入统一生成框架。

4 VLA 与 WAM 的区别

VLA 主要学习：

$$p(a_t \mid o_t, \ell).$$

WAM 则学习：

$$p(a_{t:t+H-1}, o_{t+1:t+H} \mid o_{\leq t}, \ell).$$

因此，VLA 更像是

$$\text{observation} \rightarrow \text{action},$$

而 WAM 更像是

$$\text{observation} \rightarrow \text{future world} + \text{action}.$$

从 representation learning 的角度看，WAM 的潜在收益来自未来预测目标对隐表示 z_t 的约束。理想情况下， $z_t = f_{\theta}(o_{\leq t})$ 需要携带物理动态、物体交互和任务进展信息。可以直观理解为提高：

$$I(z_t; o_{t+1:t+H} \mid o_{\leq t}, a_{t:t+H-1}, \ell),$$

即隐表示与未来观测之间的条件互信息。

5 三类 WAM 范式

5.1 Joint Video-Action Modeling

联合视频与动作建模直接学习：

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

若使用扩散模型，可令

$$x_0 = [o_{t+1:t+H}, a_{t:t+H-1}], \quad c = [o_{\leq t}, \ell].$$

标准 denoising loss 为:

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{x_0, \epsilon, \tau} \left[\|\epsilon - \epsilon_\theta(x_\tau, \tau, c)\|_2^2 \right].$$

这里未来视频 token 和 action token 被放在同一个生成对象中。

5.2 Imagine-Then-Execute

这类方法先生成未来:

$$\hat{o}_{t+1:t+H} \sim p_\theta(o_{t+1:t+H} \mid o_{\leq t}, \ell),$$

再根据想象出的未来预测动作:

$$a_{t:t+H-1} \sim \pi_\phi(a_{t:t+H-1} \mid o_{\leq t}, \hat{o}_{t+1:t+H}, \ell).$$

直觉是: 如果模型能想象任务成功的未来状态, 动作模型就可以反推出通往该未来的动作。缺点是测试时通常需要多步视频扩散去噪, 推理延迟高。

5.3 Fast-WAM

Fast-WAM 将训练目标和推理过程解耦。训练时仍使用视频预测:

$$\mathcal{L} = \mathcal{L}_{\text{action}} + \lambda \mathcal{L}_{\text{video}}.$$

但测试时不显式生成未来视频, 而是直接预测动作:

$$a_{t:t+H-1} \sim \pi_\theta(a_{t:t+H-1} \mid z_t, \ell), \quad z_t = f_\theta(o_{\leq t}).$$

因此, Fast-WAM 的核心问题是: WAM 的收益究竟来自测试时 future imagination, 还是来自训练时 video prediction 对世界表征的塑造?

6 阅读论文时应追问的问题

1. 模型实际近似的是哪个条件分布?
2. 未来观测、动作、proprioception 和 value 是联合生成, 还是分阶段生成?
3. 视频预测目标只用于训练, 还是也参与测试时决策?
4. 动作是单步预测, 还是 action chunk?
5. 推理时是否进行 best-of- N sampling、value ranking 或 model-based planning?
6. 性能提升来自更强的世界表征, 还是来自显式规划?

7 建议阅读顺序

建议先读 Fast-WAM, 因为它的问题意识最清楚: WAM 是否真的需要测试时想象未来。然后读 Cosmos Policy, 因为它是更完整的系统, 包含 action、future state、value 和 planning。最后再读 WM as simulator, 因为它更像是把 world model 当作数据生成器或仿真器的应用, 而不是 WAM 的入门核心。