

World Action Models: 从世界建模到动作生成

核心论点: WAM

不是视频生成模型的简单下游应用, 而是把未来世界、动作序列与任务价值统一进控制问题的建模范式。


World Model
model the world

Policy / VLA
choose an action

WAM
model the world for action

只学 observation $\rightarrow$ action 会丢掉动作后果这一层结构

具身智能中的动作是干预变量：它不仅由当前观测决定，也会改变未来观测分布。WAM关注的正是这种“动作—未来”耦合。



World Model 与 WAM 的区别，核心在于 action 的角色

模型	核心问题	动作角色	典型用途
World Model	给定动作后，世界如何演化？	条件变量	预测、仿真、rollout
Policy / VLA	当前观测下，应该执行什么？	输出变量	直接控制
WAM	动作与未来世界如何联合产生？	建模对象 + 控制变量	控制、规划、表征学习

结论：WAM 不是替代 World Model，而是将 world modeling 放进 action generation / planning 的目标函数中。

Planning 将 learned model 转化为动作选择程序

Synthetic rollout 是模型内部生成的虚拟未来；planning 则在这些虚拟未来上比较候选动作，并执行最高价值候选的第一个动作或 action chunk。



Bellman intuition: 当前收益 + 后继状态的未来价值

三种 WAM 范式的分歧：future prediction 用在训练还是推理？

Joint Video-Action

动作与未来视频在同一个生成过程中联合去噪。

训练：联合预测
推理：显式生成未来 + 动作

Imagine-Then-Execute

先想象目标未来，再由 inverse dynamics / action decoder 反推动作。

训练：分阶段
推理：先未来，后动作

Fast-WAM


训练时保留视频预测，推理时只用 latent world representation 直接出动作。

训练：视频辅助监督
推理：跳过未来生成

判别轴：显式 imagination 是否仍是 test-time action selection 的必要步骤。

Joint Video-Action 让动作和未来画面互相约束

训练样本不是单独的图像或动作，而是未来视觉 latent 与动作 token 的联合对象。扩散模型学习在条件观测和语言下恢复这个联合样本。



优点：多模态动作分布；动作与未来一致。 **代价：**推理时 denoising 高维未来，延迟较高。

先想象未来再执行，清晰但引入一致性瓶颈

这一范式把问题拆成 future model 与 action


model：前者生成目标未来，后者学习如何从当前状态到达该未来。



failure mode: imagined future may be visually plausible but not robot-executable

Fast-WAM 把未来预测从推理步骤改造成表征监督

关键不是“不要 world model”，而是：训练时仍用 future prediction 迫使 latent 学世界动态；测试时不再显式生成未来视频。



扩散在 WAM 中是分布学习机制，不只是视频渲染器

训练时，模型从被加噪的联合样本中预测噪声。它学习的是条件分布的形状，尤其适合多峰动作和多种可能未来。



对 Fast-WAM 来说，扩散/视频预测的主要价值是训练出更懂动力学的 latent，而不是每次控制都生成完整未来。

核心问题：世界模型的价值在显式想象，还是在 latent supervision?

If explicit imagination matters

- generate candidate futures
- rank by value
- execute

If representation matters

- train with video prediction
- use z_t directly
- reduce latency

Research agenda

- compare both factors
- measure latency / success
- inspect rollout errors

Takeaway

WAM

的学术价值不在于“会生成视频”，而在于它把世界动态、动作生成与规划价值放到同一个可检验的问题框架中。