

World Action Models 系统学习笔记

2026 年 6 月 26 日

目录

1 学习主线	2
2 从 POMDP 到 WAM	2
3 World Model 与 WAM	2
4 Model, Planning 与 Synthetic Rollout	3
5 三种 WAM 范式	3
5.1 Joint Video-Action Modeling	3
5.2 Imagine-Then-Execute	4
5.3 Fast-WAM	4
6 扩散模型在 WAM 中的作用	5
7 三篇材料的位置	5
8 总结	5

1 学习主线

World Action Model, 简称 WAM, 不只是一个会生成未来视频的模型。更严格地说, 它研究的是: 在部分可观测、语言条件、连续控制的序列决策问题中, 如何联合建模世界动态、动作分布与任务价值, 并将这种建模能力用于策略学习、规划或机器人控制。

WAM 位于多个方向的交叉处: POMDP、world model、imitation learning、video prediction、diffusion policy、model-based planning 和 embodied AI。入门时应抓住一个核心问题: 模型是否只需要直接输出动作, 还是需要同时理解动作会如何改变世界。

2 从 POMDP 到 WAM

具身控制任务可以形式化为一个部分可观测马尔可夫决策过程:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{O}, T, \Omega, R, \gamma).$$

其中 $\mathcal{S}$ 是真实状态空间, $\mathcal{A}$ 是动作空间, $\mathcal{O}$ 是观测空间, T 是环境动力学, Ω 是观测模型, R 是奖励函数, γ 是折扣因子。

机器人通常无法直接访问真实状态, 只能得到图像、多视角视频或 proprioception。若任务由语言给出, 记语言指令为 ℓ 。普通策略模型主要学习:

$$\pi_{\theta}(a_t \mid o_{\leq t}, a_{< t}, \ell).$$

很多 VLA 模型进一步近似为:

$$\pi_{\theta}(a_t \mid o_t, \ell).$$

WAM 的区别在于, 它不只学习动作分布, 还学习动作和未来世界之间的耦合关系:

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

3 World Model 与 WAM

World Model 的核心是建模世界如何演化。经典形式是:

$$p_{\theta}(s_{t+1} \mid s_t, a_t),$$

在视觉机器人中更常写为:

$$p_{\theta}(o_{t+1:t+H} \mid o_{\leq t}, a_{t:t+H-1}).$$

它回答的问题是: 如果在当前世界中采取某个动作, 未来世界会怎样?

WAM 则更强调控制导向的联合建模:

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

也就是说, World Model 更像预测器或 learned simulator; WAM 更像带世界预测能力的动作模型。

模型类型	主要问题	数学对象
World Model	动作之后世界如何变化	$p(o_{future} \mid o_{past}, a_{future})$
Policy/VLA	当前应该做什么动作	$p(a_t \mid o_t, \ell)$
WAM	动作和未来世界如何联合建模	$p(o_{future}, a_{future} \mid o_{past}, \ell)$

4 Model, Planning 与 Synthetic Rollout

在 world model 和 WAM 文献中, model、planning 和 synthetic rollout 是三个相关但不等价的概念:

model = 学到的环境近似, planning = 利用模型选择动作, synthetic rollout = 模型内部生成的虚拟轨迹

真实 rollout 来自真实环境:

$$\tau = (o_0, a_0, o_1, a_1, \dots, o_T).$$

Synthetic rollout 则来自学到的模型:

$$\hat{\tau} = (o_t, a_t, \hat{o}_{t+1}, a_{t+1}, \hat{o}_{t+2}, \dots, \hat{o}_{t+H}).$$

其中未来观测由模型采样或生成, 而不是由传感器真实采集。

Planning 的目标是利用模型比较候选动作序列, 选择期望回报最高的动作。更完整的有限时域规划还可以加入 terminal value。若模型预测 value, WAM 可以对多个候选未来进行排序, 只执行得分最高候选的第一个动作或 action chunk。

Synthetic rollout 的主要风险是模型误差和误差累积。单步预测可能只略有偏差, 但多步展开后, 预测轨迹可能逐渐偏离真实环境。此外, planner 可能利用模型漏洞, 找到在模型中得分高但在真实世界不可行的动作。

5 三种 WAM 范式

5.1 Joint Video-Action Modeling

这一范式把未来观测和动作放在同一个生成建模问题中:

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

模型同时回答两个问题: 未来世界会怎样变化, 哪些动作与这些未来变化相匹配。

若使用扩散模型, 可令干净样本为:

$$x_0 = [z_{t+1:t+H}^o, z_{t:t+H-1}^a],$$

其中 z^o 是未来视频或图像的 latent token, z^a 是动作 token。条件为:

$$c = [o_{\leq t}, \ell].$$

训练时随机加噪：

$$x_\tau = \sqrt{\bar{\alpha}_\tau}x_0 + \sqrt{1 - \bar{\alpha}_\tau}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

模型看到带噪样本、噪声等级和条件信息，任务是预测被加入的噪声：

$$\mathcal{L}_{\text{joint}} = \mathbb{E}_{x_0, \epsilon, \tau} \left[\|\epsilon - \epsilon_\theta(x_\tau, \tau, c)\|_2^2 \right].$$

这个目标的含义是：模型必须学会在当前观测和语言指令约束下，把被污染的“未来世界 + 动作”样本去噪回真实演示数据。

5.2 Imagine-Then-Execute

这一范式分成两个阶段：先想象未来，再根据未来选择动作。第一阶段生成未来观测：

$$\hat{o}_{t+1:t+H} \sim p_\theta(o_{t+1:t+H} \mid o_{\leq t}, \ell).$$

第二阶段根据当前观测和想象出的未来预测动作：

$$a_{t:t+H-1} \sim \pi_\phi(a_{t:t+H-1} \mid o_{\leq t}, \hat{o}_{t+1:t+H}, \ell).$$

训练时通常包含 future model loss 和 action model loss。前者学习生成未来，后者学习从当前状态和未来状态反推出动作。它的优点是模块化清晰，缺点是测试时生成未来视频通常很慢，而且生成未来不一定对应机器人真正可执行的动作。

5.3 Fast-WAM

Fast-WAM 的核心问题是：WAM 是否必须在测试时显式生成未来视频？它的答案倾向于否。训练时仍保留视频预测目标：

$$\mathcal{L} = \mathcal{L}_{\text{action}} + \lambda \mathcal{L}_{\text{video}}.$$

但推理时不生成未来视频，而是直接根据 latent world representation 输出动作：

$$a_{t:t+H-1} \sim \pi_\theta(a_{t:t+H-1} \mid z_t, \ell), \quad z_t = f_\theta(o_{\leq t}).$$

这里的 z_t 通常由视频或视觉模型产生，但更准确地说，它是当前时刻的 latent world state。视频预测目标的作用不是为了测试时生成真实未来，而是为了迫使 z_t 包含物理动态、物体交互和任务进展等控制相关信息。

范式	训练时预测未来	推理时生成未来	动作产生方式
Joint Video-Action	是	是	与未来视频联合生成
Imagine-Then-Execute	是	是	由想象未来反推动作
Fast-WAM	是	否	由 latent representation 直接预测

6 扩散模型在 WAM 中的作用

扩散模型不是一次性输出动作或未来视频，而是学习从噪声中逐步恢复真实数据。训练时，模型拿到被加噪的真实演示片段，并学习预测噪声；推理时，模型从纯噪声开始，逐步去噪生成合理样本。

在 WAM 中，被生成的对象不一定只有图像。它可以是未来视频 latent、动作 token、机器人状态 token，甚至 value token 的联合对象。因此扩散模型可以用于生成“未来世界 + 动作”的联合样本。

Fast-WAM 之所以推理时仍可跳过扩散生成，是因为扩散或视频预测目标主要承担训练时表征学习的角色。也就是说，扩散训练让 latent 学会世界动态；推理时则只使用这个 latent 来快速预测动作。

7 三篇材料的位置

- **Fast-WAM** 适合作为 WAM 入门论文，因为它直接追问：WAM 的收益来自测试时显式未来想象，还是来自训练时视频预测塑造出的世界表征？
- **Cosmos Policy** 更接近完整系统。它把 action、future state 和 value 纳入统一生成框架，并使用候选未来和价值预测辅助决策。
- **WM as simulator** 更像 world model 的应用论文。它关注把 world model 作为 learned simulator，用来生成训练场景、synthetic rollout 或 synthetic data。

8 总结

World Model 的核心是 model the world；WAM 的核心是 model the world for action。Joint Video-Action 强调动作和未来一起生成；Imagine-Then-Execute 强调先想象未来再反推动作；Fast-WAM 强调训练时学习未来、推理时直接行动。三者的根本分歧在于：未来预测到底应该作为测试时 planning 的显式步骤，还是只作为训练时塑造世界表征的辅助目标。