

World Model 与 World Action Model 的区别

2026 年 6 月 26 日

1 核心结论

World Model 和 World Action Model, 简称 WAM, 并不是完全并列的概念。更准确地说, WAM 可以看作一种面向动作决策和控制任务的 world model-policy hybrid。

简而言之：

World Model $\approx$ 建模世界如何演化,

WAM $\approx$ 建模世界如何演化, 并将其用于动作生成或规划。

因此, World Model 更偏动力学建模, WAM 更偏控制导向的世界-动作联合建模。

2 World Model 建模什么

经典 World Model 的核心对象是环境动力学：

$$p_{\theta}(s_{t+1} \mid s_t, a_t),$$

其中 s_t 是真实环境状态, a_t 是动作。

但在视觉机器人和具身智能中, 真实状态 s_t 通常不可直接访问, 模型只能看到图像、深度图、多视角视频或 proprioception。因此更常见的形式是：

$$p_{\theta}(o_{t+1} \mid o_{\leq t}, a_t),$$

或多步未来预测：

$$p_{\theta}(o_{t+1:t+H} \mid o_{\leq t}, a_{t:t+H-1}).$$

这类模型回答的问题是：

如果在当前世界中采取某个动作, 未来世界会怎样?

所以 World Model 主要用于：

- 预测未来 observation 或 state;
- 进行 model-based planning;
- 生成 synthetic rollout;
- 作为 learned simulator;
- 学习更好的 latent representation。

3 WAM 建模什么

WAM 不只把动作作为条件，还常常把动作本身也作为生成或预测对象。一个典型形式是：

$$p_{\theta}(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell),$$

其中 ℓ 是语言指令。

如果加入机器人自身状态 q_t 和价值 V ，则可以写成：

$$p_{\theta}(o_{t+1:t+H}, q_{t+1:t+H}, a_{t:t+H-1}, V_{t+H} \mid o_{\leq t}, q_{\leq t}, \ell).$$

WAM 回答的问题不是单纯的“世界会怎样”，而是：

为了完成任务，我该采取什么动作？这些动作会让世界如何变化？

因此，WAM 同时包含 world dynamics 和 action modeling。

4 关键数学区别

World Model 通常近似：

$$p(o_{t+1:t+H} \mid o_{\leq t}, a_{t:t+H-1}).$$

Policy 或 VLA 通常近似：

$$p(a_t \mid o_t, \ell).$$

WAM 则试图联合建模：

$$p(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell).$$

三者的区别可以概括如下：

World Model = world dynamics,

Policy/VLA = action generation,

WAM = world dynamics + action generation/control.

模型类型	主要问题	数学对象
World Model	动作之后世界如何变化	$p(o_{t+1:t+H} \mid o_{\leq t}, a_{t:t+H-1})$
Policy/VLA	当前应该做什么动作	$p(a_t \mid o_t, \ell)$
WAM	动作和未来世界如何联合建模	$p(o_{t+1:t+H}, a_{t:t+H-1} \mid o_{\leq t}, \ell)$

5 动作的角色不同

区别的核心在于动作 a_t 的角色。

在 World Model 中，动作通常是条件变量：

$$a_{t:t+H-1} \text{ conditions future prediction.}$$

也就是说，模型假设动作已经给定，然后预测未来。

在 WAM 中，动作常常既是条件相关变量，也是需要生成的目标：

$$a_{t:t+H-1} \text{ is part of the modeled output.}$$

这使得 WAM 更接近策略模型，因为它最终要服务于 action selection。

6 机器人例子

假设任务是“把杯子推到目标区域”。

World Model 关心：

$$(o_t, a_t) \mapsto o_{t+1}.$$

它问的是：如果机械臂向右推，杯子下一刻会到哪里？

WAM 关心：

$$(o_t, \ell) \mapsto (a_t, o_{t+1}).$$

它问的是：为了完成“把杯子推到目标区域”，应该采取什么动作？该动作会让场景变成什么样？

7 与三篇材料的对应关系

- **WM as simulator** 更接近 World Model 的应用：把 world model 当作 learned simulator，用来生成场景、rollout 或训练数据。
- **Cosmos Policy** 更接近完整 WAM：它联合处理 action、future state、value，并支持 planning。
- **Fast-WAM** 则追问：WAM 的收益主要来自 test-time future imagination，还是来自 training-time video prediction 对表示学习的作用？

8 一句话总结

World Model 的核心是：

$$\text{model the world.}$$

WAM 的核心是：

$$\text{model the world for action.}$$

前者更像预测器或模拟器，后者更像带世界预测能力的动作模型。